

Usando Redes Neurais Guiadas pela Física (PINNs) para resolver EDPs

Laboratório de Dinâmica dos Fluidos Computacional

Prof. Roberto Ribeiro Santos Júnior

Prof. Thiago de Oliveira Quinelato

Guilherme Furquim

Guilherme Ozanski

Larry Steffen Bertoncello

Lucas Xavier

Samuel Kutz Paranhos

Universidade Federal do Paraná

8 de novembro de 2024

LabFluid

Apresentação

Professores

► Professores:

- Profa. Ailin Ruiz de Zarate Fabregas
- Prof. Elias Alfredo Gudiño Rojas
- Prof. Roberto Ribeiro Santos Jr.
- Prof. Thiago de Oliveira Quinelato



Sumário

1. LabFluid
2. Equações Diferenciais Parciais (EDPs)
3. Método de Diferenças Finitas
4. Redes Neurais
5. PINNs

Equações Diferenciais Parciais (EDPs)

Equações Diferenciais Parciais (EDPs)

Introdução

No contexto de modelagem matemática, muitas vezes encontramos cenários onde modelamos um problema como a solução de equações.

Alguns tipos comuns de equações são:

- ▶ equações algébricas (soluções são números);
- ▶ relações de recorrência (soluções são sequências);
- ▶ equações diferenciais ordinárias/parciais (soluções são **funções**).

Em equações diferenciais, estamos à procura de **funções** que satisfazem as equações do nosso modelo.

Equações Diferenciais Parciais (EDPs)

Introdução

No contexto de modelagem matemática, muitas vezes encontramos cenários onde modelamos um problema como a solução de equações.

Alguns tipos comuns de equações são:

- ▶ equações algébricas (soluções são números);
- ▶ relações de recorrência (soluções são sequências);
- ▶ equações diferenciais ordinárias/parciais (soluções são **funções**).

Em equações diferenciais, estamos à procura de **funções** que satisfazem as equações do nosso modelo.

Equações Diferenciais Parciais (EDPs)

Introdução

No contexto de modelagem matemática, muitas vezes encontramos cenários onde modelamos um problema como a solução de equações.

Alguns tipos comuns de equações são:

- ▶ equações algébricas (soluções são números);
- ▶ relações de recorrência (soluções são sequências);
- ▶ **equações diferenciais ordinárias/parciais** (soluções são **funções**).

Em equações diferenciais, estamos à procura de **funções** que satisfazem as equações do nosso modelo.

Equações Diferenciais Parciais (EDPs)

Exemplo de EDO

Equações diferenciais ordinárias envolvem encontrar uma função de uma variável que satisfaz certas condições sobre suas derivadas, por exemplo:

► Problema de Valor Inicial (EDO):

$$\begin{cases} \mathbf{y}'(t) &= \lambda \mathbf{y}(t) & \lambda \in \mathbb{R}, \\ \mathbf{y}(0) &= y_0, \end{cases}$$

com $y : \mathbb{R} \rightarrow \mathbb{R}$.

► Solução:

$$y(t) = y_0 e^{\lambda t} \quad (\text{uma função})$$

Equações Diferenciais Parciais (EDPs)

Exemplo de EDO

Equações diferenciais ordinárias envolvem encontrar uma função de uma variável que satisfaz certas condições sobre suas derivadas, por exemplo:

► Problema de Valor Inicial (EDO):

$$\begin{cases} \mathbf{y}'(t) &= \lambda \mathbf{y}(t) & \lambda \in \mathbb{R}, \\ \mathbf{y}(0) &= y_0, \end{cases}$$

com $y : \mathbb{R} \rightarrow \mathbb{R}$.

► Solução:

$$\mathbf{y}(t) = y_0 e^{\lambda t} \quad (\text{uma função})$$

Equações Diferenciais Parciais (EDPs)

Exemplo de EDP

Equações diferenciais parciais envolvem encontrar uma função de várias variáveis que satisfaz condições sobre suas derivadas parciais. Mais especificadamente, tome o seguinte exemplo:

► Equação do Calor (EDP):

$$\begin{aligned}u_t &= \alpha u_{xx}, & (x, t) &\in (-\pi, \pi) \times (0, 6), \\u(x, 0) &= f(x), & x &\in (-\pi, \pi), & u(\pm\pi, t) &= 0, & t &\in (0, 6),\end{aligned}$$

onde $u = u(x, t)$, $\alpha = 1$ e $f(x) = 3 \sin(x)$.

► Solução:

$$u(x, t) = 3e^{-t} \sin(x)$$

gif da equação

Equações Diferenciais Parciais (EDPs)

Exemplo de EDP

Equações diferenciais parciais envolvem encontrar uma função de várias variáveis que satisfaz condições sobre suas derivadas parciais. Mais especificadamente, tome o seguinte exemplo:

► Equação do Calor (EDP):

$$\begin{aligned}u_t &= \alpha u_{xx}, & (x, t) &\in (-\pi, \pi) \times (0, 6), \\u(x, 0) &= f(x), & x &\in (-\pi, \pi), & u(\pm\pi, t) &= 0, & t &\in (0, 6),\end{aligned}$$

onde $u = u(x, t)$, $\alpha = 1$ e $f(x) = 3 \sin(x)$.

► Solução:

$$u(x, t) = 3e^{-t} \sin(x)$$

gif da equação

Método de Diferenças Finitas

Diferenças Finitas

Construção do Método

O método de diferenças finitas, por exemplo, procura aproximar a solução de uma equação diferencial parcial substituindo o operador diferencial por um operador de diferenças.

Vamos aplicar o esquema de Diferenças Finitas na Equação do Transporte.

$$\begin{aligned}u_x + au_t &= 0 & (x, t) &\in (-3, 3) \times (0, 1), \\u(x, 0) &= f(x) & x &\in (-3, 3),\end{aligned}$$

onde $u = u(x, t)$, $a = 2$ e $f(x) = e^{-10x^2}$.

Diferenças Finitas

Construção do Método

O método de diferenças finitas, por exemplo, procura aproximar a solução de uma equação diferencial parcial substituindo o operador diferencial por um operador de diferenças.

Vamos aplicar o esquema de Diferenças Finitas na Equação do Transporte.

$$\begin{aligned}u_x + au_t &= 0 & (x, t) &\in (-3, 3) \times (0, 1), \\u(x, 0) &= f(x) & x &\in (-3, 3),\end{aligned}$$

onde $u = u(x, t)$, $a = 2$ e $f(x) = e^{-10x^2}$.

Diferenças Finitas

Construção do Método

Primeiro, aproximamos as derivadas da equação:

$$u_t(x, t) = \lim_{\Delta t \rightarrow 0} \frac{u(x, t + \Delta t) - u(x, t)}{\Delta t}$$

$$u_x(x, t) = \lim_{\Delta x \rightarrow 0} \frac{u(x - \Delta x, t) - u(x, t)}{-\Delta x}$$

$$u_t(x, t) \approx \frac{u(x, t + \Delta t) - u(x, t)}{\Delta t}$$

$$u_x(x, t) \approx \frac{u(x, t) - u(x - \Delta x, t)}{\Delta x}$$

Diferenças Finitas

Construção do Método

Primeiro, aproximamos as derivadas da equação:

$$u_t(x, t) = \lim_{\Delta t \rightarrow 0} \frac{u(x, t + \Delta t) - u(x, t)}{\Delta t}$$

$$u_x(x, t) = \lim_{\Delta x \rightarrow 0} \frac{u(x - \Delta x, t) - u(x, t)}{-\Delta x}$$


$$u_t(x, t) \approx \frac{u(x, t + \Delta t) - u(x, t)}{\Delta t}$$

$$u_x(x, t) \approx \frac{u(x, t) - u(x - \Delta x, t)}{\Delta x}$$

Diferenças Finitas

Construção do Método

$$u(x, t) = u(j\Delta x, n\Delta t) = u_j^n$$



Diferenças Finitas

Construção do Método

$$[u_t]_j^n \approx \frac{u_j^{n+1} - u_j^n}{\Delta t}; \quad [u_x]_j^n \approx \frac{u_j^n - u_{j-1}^n}{\Delta x}$$

$$[u_t]_j^n + a[u_x]_j^n = 0$$

$$\frac{u_j^{n+1} - u_j^n}{\Delta t} + a \frac{u_j^n - u_{j-1}^n}{\Delta x} = 0$$

Operador Diferencial:

$$\mathcal{D}u = u_t + au_x$$

Operador de Diferenças:

$$Du = \frac{u_j^{n+1} - u_j^n}{\Delta t} + a \frac{u_j^n - u_{j-1}^n}{\Delta x}$$

Diferenças Finitas

Construção do Método

$$[u_t]_j^n \approx \frac{u_j^{n+1} - u_j^n}{\Delta t}; \quad [u_x]_j^n \approx \frac{u_j^n - u_{j-1}^n}{\Delta x}$$

$$[u_t]_j^n + a[u_x]_j^n = 0$$

$$\frac{u_j^{n+1} - u_j^n}{\Delta t} + a \frac{u_j^n - u_{j-1}^n}{\Delta x} = 0$$

Operador Diferencial:

$$\mathcal{D}u = u_t + au_x$$

Operador de Diferenças:

$$Du = \frac{u_j^{n+1} - u_j^n}{\Delta t} + a \frac{u_j^n - u_{j-1}^n}{\Delta x}$$

Diferenças Finitas

Construção do Método

$$\frac{u_j^{n+1} - u_j^n}{\Delta t} + a \frac{u_j^n - u_{j-1}^n}{\Delta x} = 0$$

$$u_j^{n+1} = u_j^n - a \frac{\Delta t}{\Delta x} (u_j^n - u_{j-1}^n); \quad \lambda = a \frac{\Delta t}{\Delta x}$$

$$u_j^{n+1} = u_j^n - \lambda (u_j^n - u_{j-1}^n)$$

Da condição inicial da EDP:

$$u(x, 0) = f(x) = e^{-10x^2} \Leftrightarrow u_j^0 = e^{-10(j\Delta x)^2}$$

A partir dos valores u_j^0 conseguimos construir a solução em tempos maiores que zero.

Diferenças Finitas

Construção do Método

$$\frac{u_j^{n+1} - u_j^n}{\Delta t} + a \frac{u_j^n - u_{j-1}^n}{\Delta x} = 0$$

$$u_j^{n+1} = u_j^n - a \frac{\Delta t}{\Delta x} (u_j^n - u_{j-1}^n); \quad \lambda = a \frac{\Delta t}{\Delta x}$$

$$u_j^{n+1} = u_j^n - \lambda (u_j^n - u_{j-1}^n)$$

Da condição inicial da EDP:

$$u(x, 0) = f(x) = e^{-10x^2} \Leftrightarrow u_j^0 = e^{-10(j\Delta x)^2}$$

A partir dos valores u_j^0 conseguimos construir a solução em tempos maiores que zero.

Diferenças Finitas

Testes Numéricos




Figura: Comparação da Solução com $\lambda = 1$; $t = \{0, 0.5, 1\}$

Diferenças Finitas

Testes Numéricos




Figura: Comparação da Solução com $\lambda = 0.6$; $t = \{0, 0.501, 0.999\}$

Diferenças Finitas

Testes Numéricos

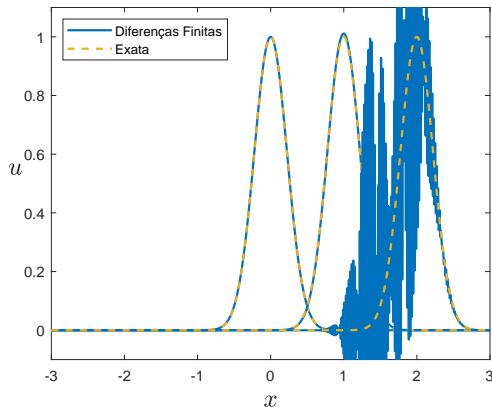


Figura: Comparação da Solução com $\lambda = 1.11$; $t = \{0, 0.4995, 0.999\}$

Redes Neurais

Redes Neurais

Estrutura




Figura: Rede Neural com 3 camadas

Redes Neurais

Estrutura

Essencialmente uma rede neural é uma **função parametrizada** $f(x; \theta)$:

- ▶ x representa os dados de entrada
- ▶ θ representa os parâmetros do modelo (pesos e vieses).
- ▶ Através do ajuste de θ , f tentará **aproximar** uma saída desejada específica para cada x .

Redes Neurais

Estrutura

Essencialmente uma rede neural é uma **função parametrizada** $f(x; \theta)$:

- ▶ x representa os dados de entrada
- ▶ θ representa os parâmetros do modelo (pesos e vieses).
- ▶ Através do ajuste de θ , f tentará **aproximar** uma saída desejada específica para cada x .

Redes Neurais

Estrutura

Essencialmente uma rede neural é uma **função parametrizada** $f(x; \theta)$:

- ▶ x representa os dados de entrada
- ▶ θ representa os parâmetros do modelo (pesos e vieses).
- ▶ Através do ajuste de θ , f tentará **aproximar** uma saída desejada específica para cada x .

Redes Neurais

Estrutura

Uma rede neural simples pode ser representada como:

$$f(x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2)$$

onde:

- ▶ W_1 e W_2 são as matrizes de pesos;
- ▶ b_1 e b_2 são os vetores de bias;
- ▶ σ é uma função de ativação não linear.

Redes Neurais

Estrutura

Uma rede neural simples pode ser representada como:

$$f(x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2)$$

onde:

- ▶ W_1 e W_2 são as matrizes de pesos;
- ▶ b_1 e b_2 são os vetores de bias;
- ▶ σ é uma função de ativação não linear.

Redes Neurais

Estrutura

Uma rede neural simples pode ser representada como:

$$f(x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2)$$

onde:

- ▶ W_1 e W_2 são as matrizes de pesos;
- ▶ b_1 e b_2 são os vetores de bias;
- ▶ σ é uma função de ativação não linear.

Redes Neurais

Exemplo

Considere uma rede neural que tenta acertar o número escrito numa imagem.

Modus Operandi:

- Prover um banco de imagens como entrada x ;
- A partir de uma configuração inicial de pesos e viéses(θ) a rede fará um chute;
- Se a alteração conforme a magnitude do erro;
- A rede chuta mais uma vez, e o processo repete.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo

Considere uma rede neural que tenta acertar o número escrito numa imagem.

Modus Operandi:

- ▶ Prover um banco de imagens como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e viéses**(θ) a rede fará um chute;
- ▶ θ é alterado conforme a magnitude do erro.
- ▶ A rede chuta mais uma vez, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo

Considere uma rede neural que tenta acertar o número escrito numa imagem.

Modus Operandi:

- ▶ Prover um banco de imagens como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e viéses(θ)** a rede fará um chute;
- ▶ θ é alterado conforme a magnitude do erro.
- ▶ A rede chuta mais uma vez, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo

Considere uma rede neural que tenta acertar o número escrito numa imagem.

Modus Operanti:

- ▶ Prover um banco de imagens como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e viéses(θ)** a rede fará um chute;
- ▶ θ é alterado conforme a magnitude do erro.
- ▶ A rede chuta mais uma vez, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo

Considere uma rede neural que tenta acertar o número escrito numa imagem.

Modus Operandi:

- ▶ Prover um banco de imagens como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e viéses(θ)** a rede fará um chute;
- ▶ θ é alterado conforme a magnitude do erro.
- ▶ A rede chuta mais uma vez, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo

Considere uma rede neural que tenta acertar o número escrito numa imagem.

Modus Operanti:

- ▶ Prover um banco de imagens como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e viéses(θ)** a rede fará um chute;
- ▶ θ é alterado conforme a magnitude do erro.
- ▶ A rede chuta mais uma vez, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo

Considere uma rede neural que tenta acertar o número escrito numa imagem.


Modus Operandi:

- ▶ Prover um banco de imagens como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e viéses(θ)** a rede fará um chute;
- ▶ θ é alterado conforme a magnitude do erro.
- ▶ A rede chuta mais uma vez, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo



PINNs

PINNs

O que é?

PINN¹ é um acrônimo para Physics Informed Neural Network, ou Rede Neural Informada de Física, em português. Que basicamente significa uma rede neural capaz de encontrar uma solução numérica para uma EDP (Equação Diferencial Parcial) – daí o *informada de física*, pois muitos fenômenos físicos são descritos por EDPs.

¹Maziar Raissi, Paris Perdikaris e George Em Karniadakis (2017). “Physics informed deep learning (part i): Data-driven solutions of nonlinear partial differential equations”. Em: *arXiv preprint arXiv:1711.10561*.

PINNs

O que é?

► Considere uma equação diferencial parcial na forma geral:

► $u_t + \mathcal{N}[u; \lambda] = 0.$

► Onde \mathcal{N} é um operador diferencial (possivelmente não-linear) parametrizado por λ

► Nessa formulação, a equação do transporte é descrita com $\mathcal{N}[u; a] = au_x$, assim $u_t + au_x = 0.$

► Sendo $u(x, t)$ a solução da EDP em questão, para $x \in \Omega \subset \mathbb{R}^D$ e $t \in [0, T]$.

PINNs

O que é?

- ▶ Considere uma equação diferencial parcial na forma geral:
- ▶ $u_t + \mathcal{N}[u; \lambda] = 0$.
- ▶ Onde \mathcal{N} é um operador diferencial (possivelmente não-linear) parametrizado por λ
- ▶ Nessa formulação, a equação do transporte é descrita com $\mathcal{N}[u; a] = au_x$, assim $u_t + au_x = 0$.
- ▶ Sendo $u(x, t)$ a solução da EDP em questão, para $x \in \Omega \subset \mathbb{R}^D$ e $t \in [0, T]$.

PINNs

O que é?

- ▶ Considere uma equação diferencial parcial na forma geral:
- ▶ $u_t + \mathcal{N}[u; \lambda] = 0$.
- ▶ Onde \mathcal{N} é um operador diferencial (possivelmente não-linear) parametrizado por λ
- ▶ Nessa formulação, a equação do transporte é descrita com $\mathcal{N}[u; a] = au_x$, assim $u_t + au_x = 0$.
- ▶ Sendo $u(x, t)$ a solução da EDP em questão, para $x \in \Omega \subset \mathbb{R}^D$ e $t \in [0, T]$.

PINNs

O que é?

- ▶ Considere uma equação diferencial parcial na forma geral:
- ▶ $u_t + \mathcal{N}[u; \lambda] = 0$.
- ▶ Onde \mathcal{N} é um operador diferencial (possivelmente não-linear) parametrizado por λ
- ▶ Nessa formulação, a equação do transporte é descrita com $\mathcal{N}[u; a] = au_x$, assim $u_t + au_x = 0$.
- ▶ Sendo $u(x, t)$ a solução da EDP em questão, para $x \in \Omega \subset \mathbb{R}^D$ e $t \in [0, T]$.

PINNs

O que é?

- ▶ Considere uma equação diferencial parcial na forma geral:
- ▶ $u_t + \mathcal{N}[u; \lambda] = 0$.
- ▶ Onde \mathcal{N} é um operador diferencial (possivelmente não-linear) parametrizado por λ
- ▶ Nessa formulação, a equação do transporte é descrita com $\mathcal{N}[u; a] = au_x$, assim $u_t + au_x = 0$.
- ▶ Sendo $u(x, t)$ a solução da EDP em questão, para $x \in \Omega \subset \mathbb{R}^D$ e $t \in [0, T]$.

O que difere uma PINN de outras redes neurais é a forma como a função do erro é definida. Defina $D := u_t + \mathcal{N}[u; \lambda]$ como o lado esquerdo da equação. Vamos resolver um problema generico da forma:

$$\begin{aligned} \min |D|, & \quad (x, t) \in \Omega \times [0, T], \\ u(x, 0) = u_0(x), & \quad x \in \Omega, \\ u(x, t) = u_b(x, t), & \quad (x, t) \in \partial\Omega \times [0, T]. \end{aligned}$$

Uma PINN é capaz de aproximar $u(x, t)$ por minimizar a seguinte função de erro.

PINNs

Formulação

► $\text{EMQ} = \text{EMQ}_0 + \text{EMQ}_b + \text{EMQ}_\mathcal{D}$

► $\text{EQM}_\mathcal{D} = \frac{1}{N_\mathcal{D}} \sum_{i=1}^{N_\mathcal{D}} |\mathcal{D}(x_i, t_i)|^2$, onde (x_i, t_i) , $i = 1, \dots, N_\mathcal{D}$, representa $N_\mathcal{D}$ pontos de colocação;

► $\text{EQM}_0 = \frac{1}{N_0} \sum_{i=1}^{N_0} |(u(x_i, 0) - u_0(x_i))|^2$, onde x_i , $i = 1, \dots, N_0$ representa N_0 pontos iniciais;

► $\text{EQM}_b = \frac{1}{N_b} \sum_{i=1}^{N_b} |u(x_i, t_i) - u_b(x_i, t_i)|^2$, onde (x_i, t_i) , $i = 1, \dots, N_b$ corresponde a N_b pontos na borda;

PINNs

Formulação

► $EMQ = EMQ_0 + EMQ_b + EMQ_{\mathcal{D}}$

► $EQM_{\mathcal{D}} = \frac{1}{N_{\mathcal{D}}} \sum_{i=1}^{N_{\mathcal{D}}} |\mathcal{D}(x_i, t_i)|^2$, onde (x_i, t_i) , $i = 1, \dots, N_{\mathcal{D}}$, representa $N_{\mathcal{D}}$ pontos de colocação;

► $EQM_0 = \frac{1}{N_0} \sum_{i=1}^{N_0} |(u(x_i, 0) - u_0(x_i))|^2$, onde x_i , $i = 1, \dots, N_0$ representa N_0 pontos iniciais;

► $EQM_b = \frac{1}{N_b} \sum_{i=1}^{N_b} |u(x_i, t_i) - u_b(x_i, t_i)|^2$, onde (x_i, t_i) , $i = 1, \dots, N_b$ corresponde a N_b pontos na borda;

PINNs

DeepXDE

DeepXDE é uma biblioteca científica para aprendizado de máquina para redes neurais informadas pela física.




Figura: Lu Lu, Yale University.

PINNs

Equação do Transporte

Resolvemos via PINNs a equação do transporte para $a = 2$: $u_t + 2u_x = 0$.

Parâmetro	Valor
Domínio espacial (x)	$[-5, 15]$
Domínio temporal (t)	$[0, 7.5]$
Pontos de colocação no domínio ($N_{\mathcal{D}}$)	10 000
Pontos de colocação na fronteira (N_b)	4 000
Pontos de colocação no valor inicial (N_0)	4 000
Função de Ativação	tanh
Neurônios por camada	60
Camadas intermediárias	5
Iterações do otimizador	10 000
Taxa de Aprendizado	0.001

PINNs - Exemplo

Exemplo: Equação do Transporte

Obtemos um erro L2 relativo de no máximo 5×10^{-3} , com a seguinte evolução ao longo do tempo.




Figura: Erro Relativo L2 ao longo do tempo

PINNs

Equação do Transporte

gifs da solução